EVALUASI KINERJA MODEL *TIME SERIES* UNTUK PREDIKSI NILAI JUAL KURS KOREAN WON (KRW) PERIODE 2015 – 2025

Syafiqah Marsya Kholiyadi[1], Awalia Damayanti[1]

[1]*Universitas Islam Negeri Syarif Hidayatullah Jakarta*

Abstrak Nilai jual kurs mata uang asing, termasuk Korean Won (KRW) terhadap Rupiah, memiliki peran penting dalam stabilitas ekonomi dan pengambilan keputusan finansial. Dalam praktiknya, nilai jual kurs bersifat fluktuatif, sehingga dibutuhkan peramalan yang akurat. Meskipun telah tersedia berbagai metode peramalan deret waktu seperti ARIMA dan Exponential Smoothing, belum ada kepastian model mana yang paling sesuai untuk data nilai jual kurs KRW. Penelitian ini bertujuan untuk mengevaluasi dan membandingkan kinerja tujuh model peramalan time series dalam memprediksi nilai jual kurs KRW terhadap Rupiah untuk periode 2015 hingga 2025. Metode yang dianalisis meliputi Naive, Mean, Drift, Simple Moving Average (SMA), Simple Exponential Smoothing (SES), Holt's Linear Trend, dan ARIMA (2,1,0). Evaluasi kinerja dilakukan menggunakan dua metrik utama, yaitu Mean Squared Error (MSE) dan Mean Absolute Percentage Error (MAPE).

Hasil penelitian menunjukkan bahwa model Simple Moving Average (SMA) dengan parameter n = 2 memberikan hasil paling akurat dengan nilai MSE dan MAPE terendah dibandingkan model lainnya. Hal ini menunjukkan bahwa pola fluktuatif jangka pendek dalam data nilai jual KRW lebih tepat ditangkap oleh model sederhana seperti SMA diba ndingkan model yang mengasumsikan adanya tren jangka panjang.

Kata Kunci: prediksi, nilai jual kurs, KRW, time series, SMA, ARIMA, MAPE

I. PENDAHULUAN

Pergerakan nilai tukar mata uang asing memiliki peran yang sangat penting dalam dinamika ekonomi global. Nilai tukar tidak hanya mencerminkan kondisi fundamental ekonomi suatu negara, tetapi juga berpengaruh terhadap stabilitas perdagangan, investasi, dan sektor moneter. Salah satu mata uang yang mengalami fluktuasi signifikan dalam beberapa tahun terakhir adalah Korean Won (KRW). Kurs KRW terhadap mata uang asing, termasuk Rupiah Indonesia, menjadi perhatian dalam berbagai kepentingan ekonomi, baik bagi pelaku bisnis internasional, investor, maupun otoritas keuangan.

Dalam konteks ini, kebutuhan akan peramalan nilai tukar yang akurat menjadi semakin mendesak. Model peramalan time series telah banyak digunakan untuk memahami pola historis dan memperkirakan nilai tukar di masa depan. Beberapa metode dasar seperti naïve, drift, dan rata-rata (mean) kerap digunakan sebagai pembanding awal karena kesederhanaannya. Sementara itu, pendekatan yang lebih kompleks seperti Exponential Smoothing (termasuk Simple Moving Average (SMA), Simple Exponential Smoothing (SES), dan Holt's Linear Trend) menawarkan fleksibilitas dalam menangkap pola musiman dan tren data. Namun demikian, salah

satu pendekatan yang lebih unggul dalam menangkap karakteristik data time series yang kompleks adalah model Autoregressive Integrated Moving Average (ARIMA).

Penelitian ini bertujuan untuk mengevaluasi dan membandingkan kinerja beberapa metode time series dalam memprediksi nilai jual kurs KRW terhadap IDR selama periode 2015 hingga 2025. Evaluasi dilakukan dengan mengukur akurasi prediksi masing-masing model menggunakan metrik RMSE, dan MAPE. Dengan adanya evaluasi ini, diharapkan dapat diperoleh model yang paling sesuai dalam menggambarkan dinamika nilai tukar KRW dan memberikan hasil prediksi yang andal untuk keperluan pengambilan keputusan ekonomi.

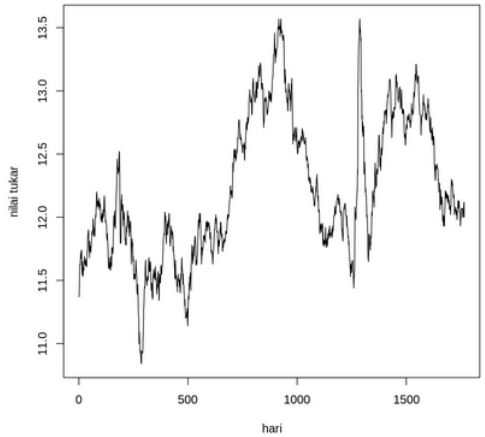
II. METODOLOGI

2.1 Data

Penelitian ini menggunakan data nilai jual kurs mata uang Korean Won (KRW) terhadap Rupiah Indonesia (IDR) untuk periode Januari 2015 hingga Maret 2025, yang diperoleh dari situs resmi Bank Indonesia (https://www.bi.go.id). Total jumlah observasi yang tersedia adalah sebanyak 2.524 data harian.

Sebelum dilakukan pemodelan, data dibagi menjadi dua bagian, yaitu 70% sebagai data pelatihan (training) dan 30% sebagai data pengujian (testing). Pembagian ini bertujuan untuk mengevaluasi performa model dalam memprediksi data yang belum terlihat oleh model (out-of-sample testing).

Data pelatihan kemudian diubah ke dalam format time series dan diberi notasi Xt, yang merepresentasikan nilai aktual kurs harian. Untuk memahami karakteristik awal data, dilakukan visualisasi dalam bentuk plot deret waktu. Berdasarkan Gambar 1, terlihat bahwa data menunjukkan indikasi tidak stasioner, baik dalam hal mean maupun varians. Namun, karena kesimpulan visual bersifat subjektif, diperlukan pengujian formal terhadap stasioneritas data.



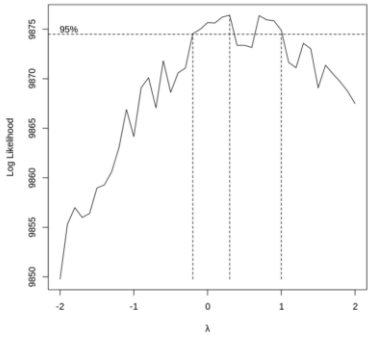
Gambar 1. Plot Data

2.2 Uji Stasioneritas

Uji stasioneritas dilakukan terhadap dua aspek, yaitu varians dan mean.

a) Uji Stasioneritas Varians Menggunakan Transformasi Box-Cox

Pemeriksaan terhadap stasioneritas varians dilakukan dengan mencari nilai lambda optimal menggunakan fungsi BoxCox.ar() di R. Berdasarkan Gambar 2, diperoleh nilai lambda optimal sebesar 0,3, yang mengindikasikan bahwa data tidak stasioner dalam varians (karena jika stasioner, nilai lambda mendekati 1).

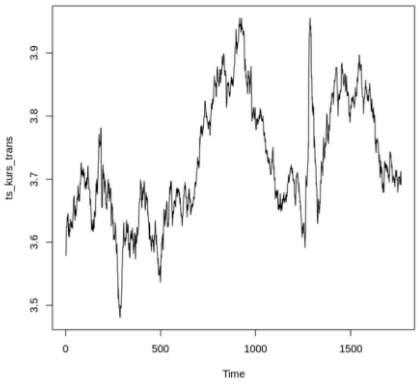


Gambar 2. Plot Uji BoxCox

Oleh karena itu, dilakukan transformasi Box-Cox pada data Xt menjadi Yt menggunakan rumus berikut:

$$y_t = \begin{cases} \dfrac{(x_t)^\lambda - 1}{\lambda}, \lambda \neq 0 \\ \ln(x_t), \lambda = 0 \end{cases}$$

Hasil transformasi divisualisasikan pada Gambar 3, yang menunjukkan bahwa data lebih stasioner dalam varians.



Gambar 3. Plot Data Train Setelah di Transformasi

b) Uji Stasioneritas Mean Menggunakan Uji ADF dan KPSS

Selanjutnya, untuk menguji stasioneritas dalam mean, digunakan dua jenis uji, yaitu Augmented Dickey-Fuller (ADF) test dan Kwiatkowski-Phillips Schmidt-Shin (KPSS) test terhadap data hasil transformasi, Yt.

- ADF Test:

  Hipotesis nol (H_0): data tidak stasioner dalam mean.

  Berdasarkan output fungsi adf.test(), yang ditampilkan pada Gambar 4, diperoleh p-value > 5%, sehingga tidak ada cukup bukti untuk menolak H_0, dan disimpulkan bahwa data tidak stasioner dalam mean.

```
    Augmented Dickey-Fuller Test

data:  ts_kurs_trans
Dickey-Fuller = -2.8007, Lag order = 12, p-value = 0.2393
alternative hypothesis: stationary
```

Gambar 4. Hasil Uji ADF

- KPSS Test:
  Hipotesis nol (H_0): data stasioner dalam mean. Berdasarkan hasil fungsi kpss.test() (Gambar 5), diperoleh p-value < 5%, sehingga H_0 ditolak, yang menguatkan kesimpulan bahwa data tidak stasioner dalam mean.

```
Warning message in kpss.test(ts_kurs_trans, null = c("Level")):
“p-value smaller than printed p-value”

    KPSS Test for Level Stationarity

data:  ts_kurs_trans
KPSS Level = 6.3927, Truncation lag parameter = 8, p-value = 0.01
```

Gambar 5. Hasil Uji KPPS

Berdasarkan hasil kedua uji tersebut, disimpulkan bahwa data Yt tidak stasioner dalam mean, sehingga perlu dilakukan differencing satu kali untuk menghilangkan tren pada data. Hasil differencing kemudian dilakukan uji ADF kembali. Berdasarkan hasil pengujian, diperoleh p- value < 5%, yang mengindikasikan bahwa data telah menjadi stasioner dalam mean setelah differencing dilakukan.

```
Warning message in adf.test(ts_kurs_diff1):
“p-value smaller than printed p-value”

    Augmented Dickey-Fuller Test

data:  ts_kurs_diff1
Dickey-Fuller = -11.034, Lag order = 12, p-value = 0.01
alternative hypothesis: stationary
```

Gambar 6. Hasil Uji ADF Setelah Differencing

2.3 Pemodelan

Penelitian ini membandingkan beberapa metode peramalan deret waktu, yaitu model dasar, model smoothing, dan model ARIMA. Pendekatan ini bertujuan untuk mengevaluasi performa masing-masing model dalam memprediksi nilai kurs KRW terhadap Rupiah, serta mengidentifikasi metode yang menghasilkan akurasi prediksi terbaik berdasarkan metrik evaluasi yang telah ditetapkan.

A) Model Dasar

Pada penelitian ini digunakan tiga model dasar yang berfungsi sebagai pembanding awal untuk menilai apakah model yang lebih kompleks memberikan peningkatan akurasi yang signifikan. Berikut adalah tiga model dasar peramalan yang digunakan dalam penelitian ini.

a. Naïve Model

Naïve model melakukan prediksi dengan mengasumsikan bahwa nilai pada periode berikutnya sama dengan nilai periode saat ini.

$$\hat{x}_{t+h} = x_t$$

Implementasi dilakukan dengan menggunakan fungsi naive() pada *software* R, dengan jumlah data testing sebanyak 758 observasi. Model ini dilatih menggunakan data Xt (data asli tanpa transformasi maupun differencing). Hasil prediksi akan dijelaskan pada bagian pembahasan selanjutnya.

b. Mean Forecast Model

Mean forecast model memprediksi nilai periode selanjutnya dengan menggunakan rata-rata seluruh nilai historis sebelumnya.

$$\hat{x}_{t+h} = \frac{1}{t}\sum_{i=1}^{t} x_i$$

Prediksi dilakukan menggunakan fungsi meanf() di R. Sama seperti model sebelumnya, data yang digunakan adalah data Xt tanpa transformasi atau differencing. Evaluasi hasil prediksi akan dibahas pada bagian berikutnya.

c. Drift Model

Drift model melakukan prediksi dengan memperhitungkan tren linier antar waktu. Model ini merupakan pengembangan dari naïve model dengan menambahkan kenaikan (drift) dari waktu ke waktu.

$$\hat{x}_{t+h} = x_t + h\left(\frac{x_t - x_1}{t-1}\right)$$

Model dibangun menggunakan fungsi rwf() dengan argumen drift = TRUE. Data pelatihan yang digunakan adalah data asli Xt dan prediksi dilakukan untuk 758 data testing.

B) Model *Exponential Smoothing*

Model *exponential smoothing* memperhitungkan bobot eksponensial terhadap data historis yang bertujuan untuk mengurangi *noise* dalam data historis, sehingga pola struktural dalam data terlihat jelas. Berikut adalah tiga model pendekatan smoothing yang digunakan dalam penelitian ini.

a. *Simple Moving Average*

Simple Moving Average (SMA) memprediksi nilai periode berikutnya dengan menghitung rata-rata dari sejumlah n periode sebelumnya.

$$S_t = \frac{(X_{t-k} + X_{t-k-1} + \ldots + X_t)}{t}$$

Model dibangun menggunakan fungsi SMA() dari paket TTR di R. Tiga nilai parameter n dicoba, dan model terbaik dipilih berdasarkan nilai MSE dan MAPE terkecil. Hasil evaluasi menunjukkan bahwa model SMA

	Model	MSE	MAPE
1	SMA n=2	0.1548265	2.555998
2	SMA n=5	0.3263281	4.223604
3	SMA n=10	0.1548265	3.527756

dengan n = 2 memberikan hasil terbaik. Data pelatihan yang digunakan adalah data Xt dan prediksi dilakukan dengan fungsi predict().

Gambar 7. Evaluasi MSE dan MAPE SMA

b. *Simple Exponential Smoothing* (SES)
Simple exponential smooting memberikan bobot lebih besar pada data terbaru dan bobot yang semakin kecil untuk data yang lebih lama, berdasarkan parameter α (alpha).

$$\hat{x}_{t+1} = \alpha x_t + (1-\alpha)\hat{x}_t$$

Model dibangun menggunakan fungsi ses() di R. Nilai alpha diestimasi secara otomatis oleh fungsi berdasarkan data pelatihan Xt. Prediksi dilakukan terhadap 758 data testing, dan hasilnya akan dianalisis pada bagian berikutnya.

c. Double Exponential Smoothing (Holt's)
Model Holt's mengembangkan SES dengan menambahkan komponen tren dalam model. Model ini memiliki dua parameter: alpha untuk komponen level dan beta untuk komponen tren.

$$Level: l_t = \alpha x_t + (1-\alpha)(l_{t-1} + b_{t-1})$$
$$Trend: b_t = \beta(l_t - l_{t-1}) + (1-\beta)b_{t-1}$$
$$Forecast: \hat{x}_{t+h} = l_t + h\,.\,b_t$$

Model diimplementasikan menggunakan fungsi holt() dari paket forecast di R. Parameter alpha dan beta diestimasi secara otomatis. Data pelatihan yang digunakan adalah data Xt dan hasil prediksi akan dibahas pada bagian pembahasan selanjutnya.

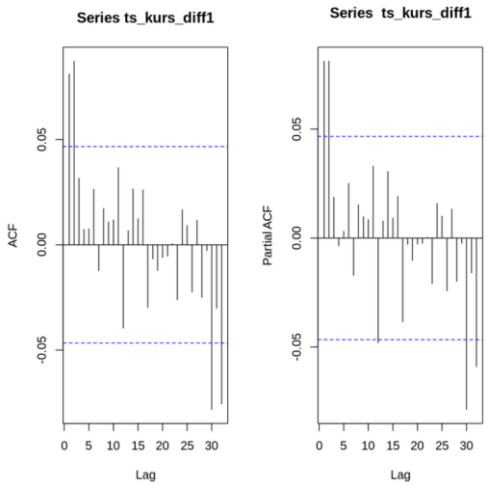
C) Model ARIMA (*Autoregressive Integrated Moving Average*)
Model ARIMA merupakan salah satu pendekatan paling umum dalam peramalan deret waktu karena kemampuannya dalam menangkap pola data yang bersifat autoregresif, terintegrasi, dan mengandung komponen rata-rata bergerak. Model ARIMA dinotasikan sebagai ARIMA(p, d, q), di mana p menunjukkan orde dari komponen autoregressive (AR), d menyatakan tingkat differencing yang dibutuhkan untuk membuat data menjadi stasioner, dan q adalah orde dari komponen moving average (MA). Secara umum, bentuk persamaan ARIMA adalah sebagai berikut:

$$\Phi_p(B)(1-B)^d Y_t = \Theta_q(B) + \varepsilon_t$$

dengan B merupakan operator backshift, $\Phi_p(B)$ dan $\Theta_q(B)$ masing-masing menyatakan polinomial dari komponen AR dan MA, serta ε_t adalah error acak (*white noise*) [1].
Dalam penelitian ini, data yang digunakan untuk pemodelan ARIMA adalah Yt , yaitu data hasil transformasi Box-Cox dari data aktual Xt. Proses pemodelan ARIMA melibatkan beberapa tahap sebagai berikut:

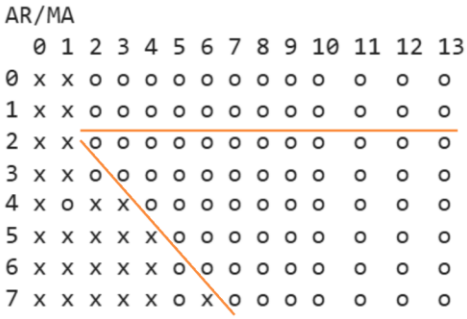
- Identifikasi Model

Tahap pertama dalam membangun model ARIMA adalah proses identifikasi model, yaitu menentukan nilai parameter p, d, dan q yang merepresentasikan orde dari komponen AR, jumlah differencing yang diperlukan untuk mencapai stasioneritas, dan orde dari komponen MA secara berurutan. Karena sebelumnya kita lakukan satu kali proses differencing, maka nilai d=1. Untuk menentukan nilai p dan q, dilakukan analisis terhadap pola plot ACF, PACF, dan EACF, serta didukung oleh hasil dari fungsi auto.arima() dan nilai kriteria BIC.



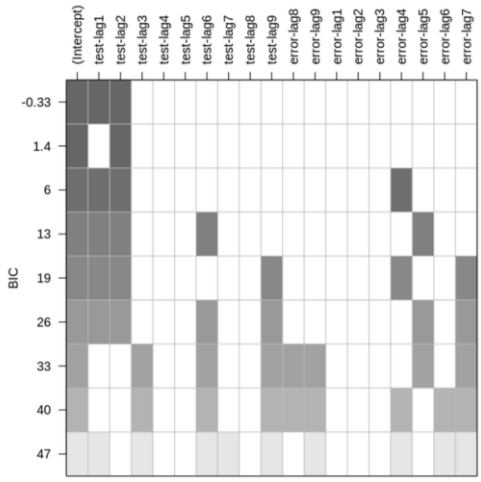
Gambar 8. Plot ACF dan PACF

Plot ACF dan PACF tidak menunjukkan pola pemotongan yang jelas, sehingga sulit untuk langsung menentukan orde yang tepat



Gambar 9. Hasil Plot EACF

Berdasarkan EACF, diperoleh kandidat model ARIMA (2,1,2).



Gambar 10. Hasil Kriteria BIC

Berdasarkan hasil dari kriteria BIC diperoleh ARIMA (2,1,0)

```
kurs_auto <- auto.arima(ts_kurs_trans)
kurs_auto
```

```
Series: ts_kurs_trans
ARIMA(2,1,0)
```

Gambar 11. Hasil auto.arima()

Berdasarkan hasil auto.arima() diperoleh model kandidat model ARIMA (2,1,0)

Oleh karena itu, dua model kandidat diajukan untuk tahap selanjutnya, yaitu ARIMA (2,1,2) dan ARIMA (2,1,0).

- Estimasi Model

  Setelah kandidat model teridentifikasi, tahap berikutnya adalah melakukan estimasi parameter model menggunakan fungsi arima() di R. Tujuan dari tahap ini adalah untuk mengestimasi koefisien pada masing-masing model dan membandingkan nilai AIC-nya. Semakin kecil nilai AIC, maka model dianggap lebih baik dalam menyesuaikan data dengan kompleksitas yang seminimal mungkin. Hasil estimasi menunjukkan bahwa model ARIMA(2,1,0) memiliki nilai AIC yang lebih rendah dibandingkan ARIMA(2,1,2), sehingga model ARIMA(2,1,0) dipilih sebagai model terbaik.

$$\Delta y_t = 0{,}0747\Delta y_{t-1} + 0{,}0817\Delta y_{t-2}$$

$$dengan\ y_t = \frac{(x_t)^{0{,}3} - 1}{0{,}3}$$

```
Call:
stats::arima(x = ts_kurs_trans, order = c(2, 1, 2))

Coefficients:
         ar1      ar2      ma1     ma2
      0.3782  -0.0336  -0.3048  0.0918
s.e.  0.4253   0.3123   0.4240  0.2871

sigma^2 estimated as 8.898e-05:  log likelihood = 5726.77,  aic = -11443.53


Call:
stats::arima(x = ts_kurs_trans, order = c(2, 1, 0))

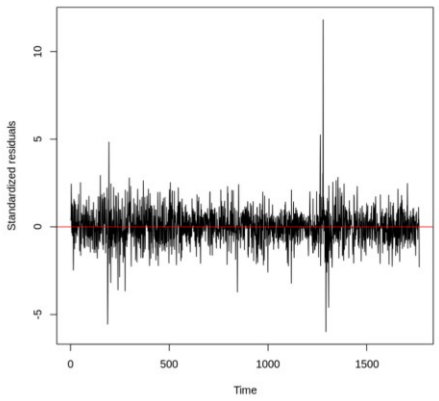
Coefficients:
         ar1     ar2
      0.0747  0.0817
s.e.  0.0237  0.0238

sigma^2 estimated as 8.901e-05:  log likelihood = 5726.48,  aic = -11446.96
```

Gambar 12. Hasil Estimasi Model ARIMA (2,1,0) dan ARIMA (2,1,2)

- Diagnosisi Model

  Diagnosis model dilakukan untuk memastikan bahwa model ARIMA yang dipilih telah memenuhi asumsi-asumsi klasik dalam analisis deret waktu, yaitu residual harus bersifat white noise, tidak berkorelasi, dan mengikuti distribusi normal. Sebelum melakukan pengujian diagnostik secara formal, terlebih dahulu dilakukan pemeriksaan visual terhadap plot residual untuk mendapatkan gambaran awal mengenai perilakunya.

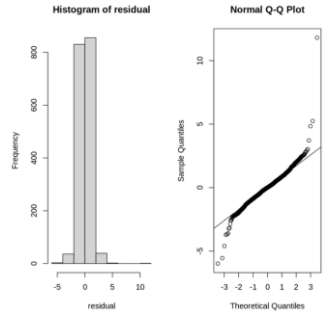


Gambar 13. Plot Residual

Berdasarkan plot tersebut, terlihat adanya indikasi keberadaan outlier pada residual, yang berpotensi memengaruhi hasil dari uji diagnostik selanjutnya.

✓ Uji normalitas residual

Uji normalitas residual dilakukan melalui visualisasi histogram dan QQ plot serta uji Shapiro-Wilk dan uji Jarque-Bera. Histogram residual menunjukkan bahwa distribusi mendekati bentuk normal, meskipun pada QQ plot terdapat deviasi di bagian ujung.



Gambar 14. Uji Normalitas Residual dengan Histogram dan QQ Plot

Untuk memperkuat analisis visual, dilakukan uji Shapiro-Wilk dan uji Jarque-Bera. Hasil kedua uji tersebut menunjukkan p-value < 0,05, yang berarti terdapat cukup bukti untuk menolak H_0 bahwa residual berdistribusi normal. Meskipun secara statistik tidak normal, secara visual residual masih dapat diterima karena tidak menunjukkan pola penyimpangan yang ekstrem.

H_0 : Residual normal
H_1 : Residual tidak normal

```
    Shapiro-Wilk normality test

data:  residual
W = 0.93877, p-value < 2.2e-16

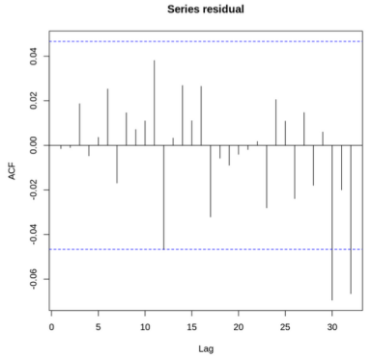
    Jarque Bera Test

data:  residual
X-squared = 12426, df = 2, p-value < 2.2e-16
```

Gambar 15. Hasil Uji Shapiro-Wilk

✓ Uji autokorelasi

Uji autokorelasi dilakukan dengan dua pendekatan, yaitu analisis visual melalui plot ACF residual serta pengujian formal menggunakan uji Ljung-Box. Hasil plot ACF menunjukkan bahwa sebagian besar spike residual berada dalam batas kepercayaan, yang mengindikasikan tidak adanya autokorelasi signifikan.



Gambar 16. Hasil Plot ACF Uji Autokorelasi

Hasil tersebut diperkuat oleh uji Ljung-Box, yang menunjukkan nilai p-value > 0,05. Dengan demikian, tidak terdapat cukup bukti untuk menolak H_0 bahwa residual bersifat independen. Ini menandakan bahwa model tidak menyisakan pola autokorelasi dalam residualnya.

H_0 : Residual Independen

H_1 : Residual Dependen

```
        Box-Ljung test

data:  residual
X-squared = 11.007, df = 15, p-value = 0.7521
```

Gambar 17. Hasil Uji Ljung Test

✓ Overparameterisasi

Overparameterisasi dilakukan untuk mengetahui apakah penambahan parameter pada model menurunkan kualitas model. Dalam tahap ini, dilakukan modifikasi model dengan menambahkan satu parameter MA, sehingga model ARIMA(2,1,0) diubah menjadi ARIMA(2,1,1). Hasil estimasi menunjukkan bahwa nilai AIC meningkat pada model baru, dan koefisien AR(1) dan MA (1) menjadi tidak signifikan. Signifikansi parameter dilihat dari rasio koefisien terhadap standar error-nya, dan nilai absolut yang terlalu kecil menunjukkan bahwa parameter tersebut tidak signifikan secara statistik. Berdasarkan hasil ini, dapat disimpulkan bahwa penambahan parameter tidak meningkatkan performa model, dan justru menimbulkan risiko overfitting. Oleh karena itu, model ARIMA (2,1,0) tetap dipilih sebagai model yang paling sesuai untuk data ini.Oleh karena itu, pada tahap ini dapat disimpulkan bahwa ARIMA (2, 1, 0) memiliki performa yang lebih baik.

```
Call:
stats::arima(x = ts_kurs_trans, order = c(2, 1, 0))

Coefficients:
         ar1     ar2
      0.0747  0.0817
s.e.  0.0237  0.0238

sigma^2 estimated as 8.901e-05:  log likelihood = 5726.48,  aic = -11446.96

Call:
stats::arima(x = ts_kurs_trans, order = c(2, 1, 1))

Coefficients:
         ar1     ar2      ma1
      0.2873  0.0645  -0.2141
s.e.  0.2721  0.0360   0.2727

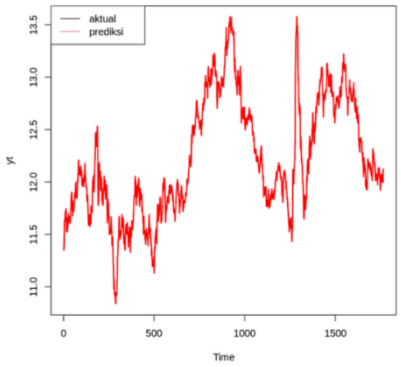
sigma^2 estimated as 8.898e-05:  log likelihood = 5726.77,  aic = -11445.54
```

Gambar 18. Hasil output estimasi model ARIMA (2, 1, 0) dan ARIMA (2, 1, 1)

- Tahap *Forecasting*

Setelah model ARIMA(2,1,0) dipilih sebagai model terbaik, langkah selanjutnya adalah melakukan peramalan terhadap data pelatihan dan

pengujian. Untuk data pelatihan, prediksi nilai dilakukan menggunakan fungsi `fitted()` yang menghasilkan output dalam bentuk YtY_tYt, dan kemudian ditransformasi balik ke skala awal XtX_tXt menggunakan fungsi `InvBoxCox()`. Hasil visualisasi menunjukkan bahwa prediksi terhadap data pelatihan sangat mendekati nilai aktual, yang menandakan bahwa model memiliki kemampuan representasi yang baik terhadap pola historis data.



Gambar 19. Perbandingan Plot Data Aktual dan Prediksi ARIMA (2,1,0)

Untuk memprediksi nilai kurs KRW pada periode pengujian (sebanyak 758 hari ke depan), digunakan fungsi `forecast()` untuk menghasilkan proyeksi ke depan. Hasil prediksi tersebut juga ditransformasi kembali ke skala asli agar dapat dibandingkan secara langsung dengan data aktual. Plot prediksi menunjukkan bahwa model mampu mengikuti pola umum pergerakan kurs, meskipun terdapat sedikit deviasi yang wajar. Hasil prediksi ini kemudian dievaluasi lebih lanjut menggunakan metrik MSE dan MAPE pada bagian selanjutnya.

2.4 Evaluasi Akurasi Model

Evaluasi akurasi dilakukan untuk mengukur sejauh mana hasil prediksi mendekati nilai aktual. Berikut adalah dua metrik utama yang digunakan dalam penelitian ini.

a) *Mean Squared Error* (MSE)

$$MSE = \frac{1}{n}\sum_{t=1}^{n}(x_t - \hat{x}_t)^2$$

MSE mengukur rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi. Nilai MSE yang rendah menunjukkan bahwa prediksi model cenderung mendekati nilai aktual secara absolut. Namun, karena satuannya adalah kuadrat dari unit data, interpretasinya bisa sulit dibandingkan antar skala berbeda.

b) *Mean Absolute Percentage Error* (MAPE)

$$MAPE = \frac{100\%}{n}\sum_{t=1}^{n}\left|\frac{x_t - \hat{x}_t}{x_t}\right|$$

MAPE mengukur rata-rata kesalahan absolut dalam bentuk persentase terhadap nilai aktual. Keunggulan MAPE adalah satuannya berupa persentase, sehingga memudahkan interpretasi antar dataset berbeda. Namun, MAPE sensitif terhadap nilai aktual yang sangat kecil (karena berada di penyebut)

Kesimpulan evaluasi akan membandingkan nilai MSE dan MAPE dari semua model (naïve, mean, drift, smoothing, ARIMA), dan model dengan nilai MSE dan MAPE terkecil akan dianggap memiliki akurasi terbaik dalam memprediksi kurs KRW.

III. HASIL DAN PEMBAHASAN

3.1 Hasil Analisis

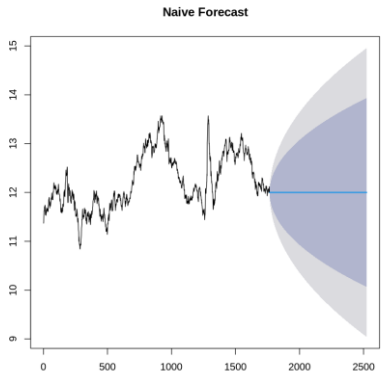
3.1.1 Hasil Prediksi

Setelah dilakukan pembangunan model menggunakan beberapa metode time series terhadap nilai jual Kurs Korean Won (KRW) terhadap rupiah periode Januari 2015 s.d. Desember 2025 diperoleh hasil prediksi sebagai berikut:

Tabel 1. Hasil Prediksi Kurs KRW

Tanggal	Nilai Aktual	Naive	Mean	Drift	SMA	SES	Holts	ARIMA (2,1,0)
22-10-2029	11.37	12	12.22036	12.00036	12.01545	12.00001	12.00050	11.99187
23-10-2019	11.4	12	12.22036	12.0071	11.97934	12.00001	12.00099	11.98151
24-10-2019	11.53	12	12.22036	12.0107	11.95008	12.00001	12.00148	11.98007
…	…	…	…	…	…	…	…	…
29-04-2025	12.12	12	12.22036	12.27020	11.82512	12.00001	12.37157	11.97880
30-04-2025	12	12	12.22036	12.27056	11.82512	12.00001	12.37206	11.97880

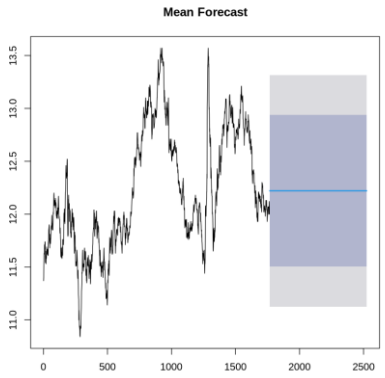
a. **Plot Prediksi Naive**



Gambar 19. Plot Forecast Model Naive

Gambar diatas menunjukkan hasil peramalan menggunakan metode *naive*, di mana nilai prediksi masa depan diambil langsung dari nilai terakhir data historis. Terlihat bahwa hasil prediksi ditunjukkan oleh garis datar yang memanjang ke depan, dengan pita biru menunjukkan interval kepercayaan (confidence interval) sebesar 80% dan 95%. Interval ini melebar seiring waktu, mengindikasikan meningkatnya ketidakpastian dalam jangka panjang.

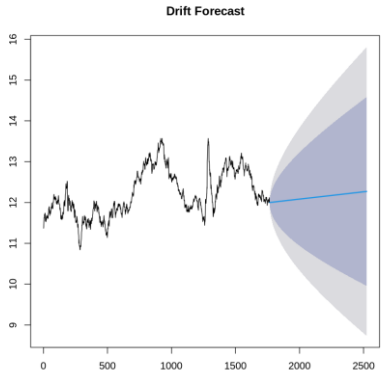
b. Plot Hasil Prediksi Mean



Gambar 20. Plot Forecast Model Mean

Gambar diatas menunjukkan hasil prediksi menggunakan metode mean forecast, yaitu memproyeksikan nilai masa depan berdasarkan rata-rata dari seluruh data historis. Garis prediksi berwarna biru terlihat konstan pada nilai tengah, tanpa mempertimbangkan adanya tren naik atau turun. Hal ini membuat model ini cenderung kurang akurat jika diterapkan pada data kurs yang bersifat fluktuatif.

c. Plot Hasil Prediksi Drift

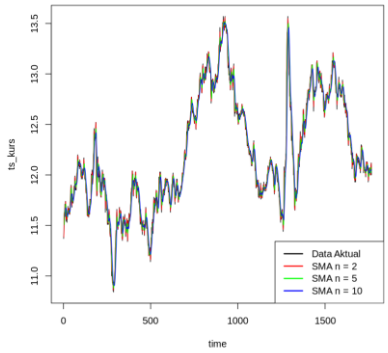


Gambar 21. Plot Forecast Model Drift

Gambar di atas menunjukkan hasil prediksi nilai tukar Korean Won menggunakan model Drift. Garis biru pada grafik merupakan proyeksi nilai

masa depan berdasarkan rata-rata perubahan data sebelumnya, dengan kecenderungan meningkat secara linear. Area bayangan biru muda dan tua merepresentasikan interval kepercayaan 80% dan 95% yang semakin melebar seiring waktu, mengindikasikan peningkatan ketidakpastian prediksi. Secara visual, model ini terlihat kurang mampu menangkap pola fluktuatif dari data aktual yang cenderung tidak memiliki tren jangka panjang yang konsisten, sehingga model Drift dinilai kurang sesuai untuk jenis data seperti nilai jual KRW.

d. Plot Hasil Prediksi SMA



Gambar 22. Perbandingan Antara Nilai Aktual dan Model SMA (n = 2, 5, 10)

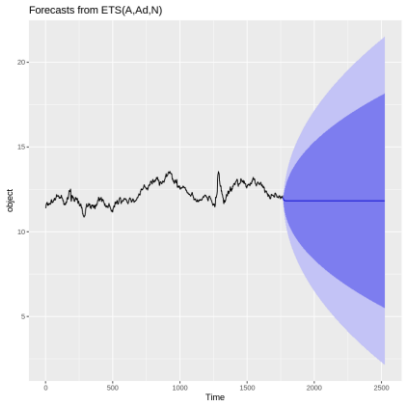
Berdasarkan uji coba terhadap beberapa nilai parameter n pada metode *Simple Moving Average* (SMA), nilai n = 2 dipilih karena menghasilkan prediksi yang paling mendekati data aktual.

Hal ini terlihat dari visualisas=, di mana garis hasil smoothing dengan n = 2 (warna merah) lebih mengikuti pergerakan data asli dibandingkan SMA dengan n = 5 atau n = 10.

	Model	MSE	MAPE
1	SMA n=2	0.1548265	2.555998
2	SMA n=5	0.3263281	4.223604
3	SMA n=10	0.1548265	3.527756

Gambar 23. Hasil Evaluasi MSE dan MAPE Model SMA (n = 2, 5, 10)

Dan diperkuat oleh hasil evaluasi menggunakan metrik MAPE (*dalam %) dan MSE yang juga menunjukkan bahwa SMA dengan n = 2 memberikan kesalahan prediksi terendah, sehingga dipilih sebagai nilai n optimal untuk model SMA pada data kurs KRW

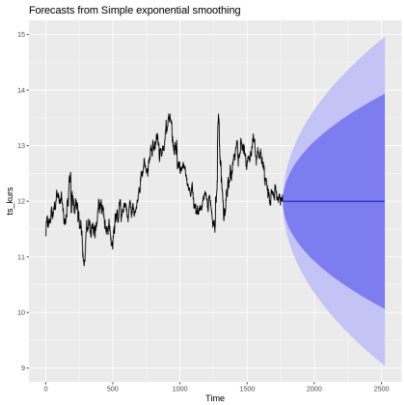


Gambar 24. Hasil Forecast Model SMA (n = 2)

Gambar di atas menunjukkan hasil prediksi nilai tukar KRW menggunakan *Simple Moving Average* (SMA) dengan parameter n = 2. Garis prediksi berlanjut secara konstan (datar), yang merupakan ciri khas dari model SMA, khususnya ketika tidak ada pembaruan data terbaru untuk periode prediksi. Area berwarna biru muda dan biru tua menunjukkan interval kepercayaan 80% dan 95%, yang semakin melebar seiring waktu, mengindikasikan bahwa tingkat ketidakpastian prediksi meningkat pada periode yang lebih jauh.

Meskipun bentuk garis prediksi terlihat sederhana, model SMA dengan n = 2 ini terbukti memberikan performa terbaik dalam hal akurasi berdasarkan nilai MAPE dan MSE yang lebih rendah dibanding model smoothing lainnya seperti SES maupun Holt. Hal ini menunjukkan bahwa perubahan kurs bersifat jangka pendek dan tidak menunjukkan tren kuat, sehingga model sederhana seperti SMA (n = 2) sudah cukup untuk menangkap pola pergerakan.

e. Plot Hasil Prediksi SES

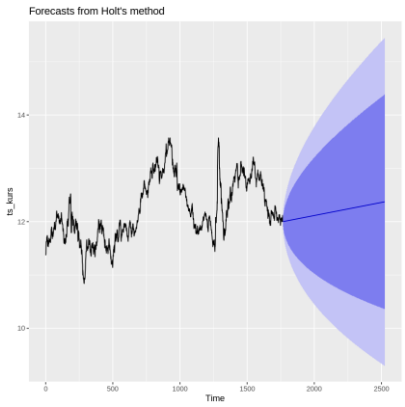


Gambar 25. Hasil Forecast Model SES

Gambar di atas menunjukkan hasil prediksi nilai tukar Korean Won menggunakan model Simple Exponential Smoothing (SES). Garis prediksi

terlihat datar mengikuti level terakhir dari data historis, mencerminkan bahwa model SES hanya mempertahankan nilai rata-rata terkini sebagai acuan untuk masa depan. Area biru muda dan biru tua menggambarkan interval kepercayaan 80% dan 95% yang semakin melebar seiring waktu, menunjukkan bahwa ketidakpastian meningkat pada periode prediksi yang lebih jauh. Secara visual, model ini kurang mampu menangkap fluktuasi signifikan dalam data, sehingga cenderung kurang sesuai untuk data kurs yang bersifat dinamis dan tidak stabil.

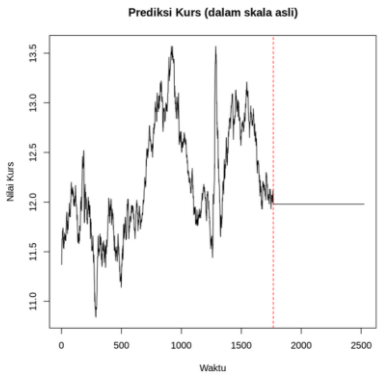
f. Plot Hasil Prediksi Holt



Gambar 26. Hasil Forecast Model Holt

Gambar di atas menampilkan hasil prediksi nilai tukar Korean Won menggunakan model Holt. Garis prediksi pada plot menunjukkan kecenderungan naik secara linier, mengikuti pola tren data historis yang ditangkap oleh model. Area berwarna biru muda dan biru tua menunjukkan interval kepercayaan 80% dan 95%, yang semakin melebar seiring waktu, menandakan bahwa ketidakpastian prediksi meningkat untuk periode yang lebih jauh. Meskipun model ini dapat menyesuaikan dengan adanya tren dalam data, visualisasi menunjukkan bahwa model Holt cenderung melebih-lebihkan arah tren, padahal pergerakan nilai tukar pada data ini relatif fluktuatif tanpa arah tren yang jelas.

g. Plot Hasil Prediksi ARIMA (2,1,0)



Gambar 27. Hasil Forecast Model ARIMA (2,1,0)

Gambar di atas menunjukkan hasil prediksi nilai tukar Korean Won menggunakan model ARIMA(2,1,0), yang dibangun berdasarkan pola autokorelasi dalam data yang telah didiferensiasi satu kali. Garis prediksi tampak datar setelah titik batas data historis, yang mengindikasikan bahwa model tidak mendeteksi adanya tren yang signifikan dalam data, sehingga nilai prediksi cenderung konstan. Hal ini dapat terjadi karena model ARIMA hanya menggunakan informasi dari nilai sebelumnya dan perubahannya, tanpa komponen musiman atau tren eksplisit. Tampilan grafik ini juga menunjukkan bahwa model ARIMA belum mampu menangkap fluktuasi tajam pada data aktual, yang membuatnya terlihat kurang adaptif terhadap pola kurs yang tidak stabil.

3.2 Evaluasi Model

Setelah dilakukan evaluasi pada setiap metode time series beriku hasil evaluasi berdasarkan MSE dan MAPE.

Tabel 2. Hasil Evaluasi MSE dan MAPE

Model	MSE	MAPE
ARIMA (2, 1, 0)	0.2407776	3.433613 %
Naive	0.2563405	3.585991 %
Mean	0.4713629	3.585991 %
Drift	0.382938	4.673684 %
SMA	0.1548265	2.555998 %
SSE	0.2563496	3.586080 %
Holt	0.4430470	5.090098 %

Berdasarkan hasil evaluasi MSE dan MAPE, model *Simple Moving Average* (SMA) memperoleh hasil evaluasi MSE dan MAPE terkecil yaitu MSE = 0.1548265 dan MAPE = 2.555998%, Kemudian Model ARIMA (2,1,0) berada di urutan kedua dengan MSE = 0.2407776 dan MAPE = 3.433613 %. Sementara itu, model lainnya seperti Naive, *Simple Exponential Smoothing* (SES), Holt, Mean, dan Drift menghasilkan error yang lebih tinggi. Sehingga didapat bahwa model time series terbaik dalam memprediksi nilai jual kurs KRW periode januari 2015 s.d. April 2025 adalah model SMA.

2. KESIMPULAN

Dari seluruh metode peramalan yang diterapkan dalam penelitian ini, model Simple Moving Average (SMA) dengan parameter $n = 2$ terbukti sebagai model yang paling optimal dalam memprediksi nilai jual Korean Won terhadap Rupiah selama

periode januari 2015 s.d. April 2025. Model ini menunjukkan kinerja terbaik karena menghasilkan nilai MSE dan MAPE terendah dibandingkan model-model lain seperti ARIMA (2,1,0), Naive, SES, Holt, dan Drift. Hasil ini mengindikasikan bahwa karakteristik data nilai jual yang tidak memiliki tren jangka panjang yang kuat dan cenderung fluktuatif lebih tepat diprediksi menggunakan model sederhana yang mampu merespons perubahan lokal secara cepat. Oleh karena itu, pendekatan seperti SMA (n = 2) dinilai lebih efektif dalam menggambarkan pola fluktuatif nilai jual kurs KRW yang bersifat jangka pendek dan tidak stabil.

DAFTAR PUSTAKA

[1] J. D.Cryer and K.-S. Chan, “Time Series Analysis With Applications in R,” 2008.

APPENDIX

Link Pengerjaan